

1. Le jeu de données Iris de Fisher contient 150 échantillons répartis en trois espèces : *Iris Setosa*, *Iris Versicolor* et *Iris Virginica* (50 échantillons chacune).

Chaque individu est décrit par 4 variables numériques continues :

- longueur du sépale (sepal length),
- largeur du sépale (sepal width),
- longueur du pétale (petal length),
- largeur du pétale (petal width).

Ces variables correspondent à des mesures botaniques destinées à différencier les espèces. Le jeu de données est équilibré et exempt de valeurs manquantes, ce qui le rend idéal pour l'apprentissage non supervisé.

2. Les labels correspondant aux espèces ont été extraits dans un vecteur distinct y , tandis que les caractéristiques numériques sont conservées dans la matrice X . Cette étape est indispensable pour le clustering non supervisé, car l'algorithme K-Means ne doit pas utiliser les classes réelles.

Ainsi, le modèle apprendra à regrouper les échantillons uniquement selon leurs caractéristiques, sans information sur les espèces d'origine.

3. Une analyse en composantes principales (PCA) a été effectuée après standardisation des variables (centrage et réduction).

La projection sur 2 composantes principales conserve environ 95 % de la variance totale (≈ 73 % pour la première composante, 23 % pour la seconde).

Cette transformation permet de réduire la dimension du jeu de données tout en maximisant la variance expliquée, ce qui facilite la visualisation et la détection des structures naturelles. Sur le graphique 2D obtenu, les échantillons d'Iris se regroupent déjà de façon distincte selon les espèces, confirmant que la PCA capture efficacement l'information discriminante.

4. Après projection des données sur deux composantes principales, l'application du K-Means avec $k = 3$ forme trois groupes bien distincts. Les centroïdes (croix noires) représentent le centre moyen de chaque cluster. On observe une séparation claire entre les individus correspondant aux espèces d'Iris, surtout entre *Iris Setosa* et les deux autres espèces. Les clusters obtenus reflètent globalement la structure naturelle du jeu de données.

5. En relançant le K-Means avec des initialisations aléatoires différentes ($\text{random_state} \neq 42$), on observe que la répartition des clusters varie légèrement. Cela s'explique par la sensibilité de l'algorithme au choix initial des centroïdes. Cependant, dans le cas du dataset Iris, les variations restent faibles car la structure des données est bien séparée. Fixer la graine aléatoire permet d'obtenir des résultats reproductibles.

6. En comparant la répartition réelle des espèces à celle issue du K-Means, on constate que *Iris Setosa* est parfaitement séparée, tandis que *Versicolor* et *Virginica* se chevauchent partiellement. Cette confusion est visible sur la projection PCA : ces deux espèces présentent des caractéristiques morphologiques très proches. Le clustering non supervisé retrouve donc naturellement deux groupes bien distincts et un troisième plus mélangé.

7. Le tableau de contingence montre une correspondance quasi parfaite entre un cluster et l'espèce *Setosa* (50/50). Les deux autres clusters se répartissent entre *Versicolor* et *Virginica*, avec plusieurs inversions (par exemple, 47 *Versicolor* et 14 *Virginica*). Ce résultat traduit une confusion logique entre ces deux variétés voisines sur le plan morphologique. Le K-Means identifie donc bien la structure principale des données sans utiliser les labels.

8. L'indice de silhouette obtenu est d'environ 0.55, ce qui indique une bonne cohésion intra-cluster et une séparation inter-cluster correcte. Une valeur proche de 1 signifierait des clusters totalement séparés ; ici, 0.55 reflète une qualité satisfaisante pour un dataset réel, en accord avec l'observation visuelle des graphes.

9. En appliquant le K-Means sur les 4 dimensions originales, les résultats restent similaires, mais les frontières entre clusters deviennent légèrement plus floues. L'indice de silhouette est souvent comparable, mais la visualisation 2D (après PCA) est plus claire pour l'interprétation humaine. Avantages des données originales : aucune perte d'information, meilleure précision numérique. Avantages de la PCA : simplification, meilleure visualisation, réduction du bruit. En pratique, la PCA est utile pour comprendre visuellement la structure tout en conservant des performances de clustering proches de celles du jeu de données initial.

PARTIE 2 :

1. La commande `AgglomerativeClustering` du module `sklearn.cluster` permet de réaliser un clustering hiérarchique ascendant.

Les principaux paramètres sont :

- `n_clusters` : nombre final de groupes souhaités (ici 3),
- `linkage` : méthode de calcul de la distance entre clusters ('complete', 'average', 'single', 'ward'),
- `affinity` (ou `metric` dans les versions récentes) : métrique de distance utilisée, généralement 'euclidean'.

2. Le linkage complet fusionne à chaque étape les deux clusters dont la distance maximale entre éléments est la plus faible.

Le dendrogramme obtenu montre une structure en trois grands groupes. En coupant à un niveau de distance ≈ 5 , on obtient 3 branches correspondant approximativement aux 3 espèces d'Iris.

Cette méthode tend à produire des clusters compacts et bien séparés, mais peut être sensible aux valeurs extrêmes.

3. Après la coupe à 3 branches, on obtient une partition des 150 échantillons en 3 clusters. Les clusters sont visualisés dans le tableau de contingence, qui montre la correspondance avec les espèces réelles.

On observe que l'espèce *Iris setosa* est presque parfaitement isolée (49/50 bien classés), tandis que *versicolor* et *virginica* sont partiellement confondues dans un même groupe.

Cela traduit la proximité morphologique entre ces deux espèces, déjà observée dans la PCA de la Partie 1.

4. Le tableau de contingence pour le linkage complet indique :

- Cluster 1 : principalement *virginica* (48) et *versicolor* (29) → mélange partiel
- Cluster 2 : essentiellement *setosa* (49) → très homogène
- Cluster 3 : quelques *versicolor* et *virginica* dispersés

L'indice de silhouette de 0.45 confirme une qualité moyenne du regroupement, satisfaisante pour un clustering non supervisé sur des données réelles.

5. Le linkage moyen (average) fusionne les clusters en fonction de la distance moyenne entre tous les points de deux groupes.

Cette approche tend à être moins sensible aux valeurs extrêmes et produit souvent des clusters plus équilibrés.

Ici, le dendrogramme montre également trois branches distinctes, et le tableau de contingence devient presque parfait :

- Un cluster pour *setosa*,
- Un pour *versicolor*,
- Un pour *virginica*.

L'indice de silhouette augmente légèrement à 0.48, ce qui traduit une meilleure homogénéité globale des groupes.

6. L'indice de silhouette du linkage moyen (0.480) est supérieur à celui du linkage complet (0.450). Cela signifie que les clusters formés avec le linkage moyen présentent une meilleure cohésion interne et une meilleure séparation entre groupes.

Ce résultat confirme visuellement que le linkage moyen fournit une partition plus fidèle à la structure réelle des données.

On peut donc conclure que, pour ce jeu de données Iris, la méthode du linkage moyen est la plus adaptée.

Partie 3 :

1. Le fichier *planete.csv* contient différentes mesures représentant les pressions partielles de gaz atmosphériques d'exoplanètes : PH₂O, PHe, PCH₄, PH₂, PN₂, PNH₃, PO₂, PAr, PCO₂, PSO₂, PK ainsi qu'une colonne finale Type indiquant la classe (label) associée. Dans le cadre de ce travail non supervisé, la colonne Type a été retirée afin que l'algorithme de clustering n'utilise aucune information sur les catégories réelles.

Les données restantes ont ensuite été normalisées (centrées et réduites) pour éviter qu'une variable de grande amplitude ne domine les autres dans le calcul des distances.

2. Deux indices ont été utilisés pour évaluer la qualité du partitionnement :

- Indice de Calinski–Harabasz (CH)

Cet indice mesure le rapport entre la dispersion inter-clusters (distance entre les centres de gravité des groupes) et la dispersion intra-cluster (cohésion interne).

→ Plus la valeur de CH est élevée, meilleure est la séparation entre les clusters.

- Indice de Davies–Bouldin (DB)

Cet indice évalue la compacité des clusters et leur séparation moyenne.
→ Plus la valeur de DB est faible, plus les clusters sont distincts et bien séparés.

Ces deux mesures sont complémentaires : CH cherche à maximiser la séparation, tandis que DB cherche à minimiser la confusion entre clusters.

3. L'approche consiste à faire varier le nombre de clusters k de 2 à 10 et à calculer, pour chaque k , les valeurs des indices CH et DB.
Ces valeurs sont ensuite tracées sous forme de courbes (méthode dite du coude).

- Sur la courbe CH, on recherche le point où le score atteint un maximum ou commence à se stabiliser.
- Sur la courbe DB, on recherche le minimum de la fonction.

Le nombre de clusters optimal correspond au point où l'ajout d'un cluster n'améliore plus significativement la qualité du partitionnement. Cette méthode permet donc de trouver un compromis entre précision et simplicité du modèle.

Dans notre cas, les indices CH et DB donnent des résultats proches :

- CH suggère un optimum à k
- DB suggère un optimum à k , ce qui traduit une structure cohérente du jeu de données, comportant probablement trois grands groupes atmosphériques distincts.

Partie 4 :

Pour cette partie, nous avons choisi un fichier de qualité de vin blanc trouvé sur UCI dans lequel nous avons supprimé des caractères afin de créer des valeurs manquantes. Nous avons également implémenté une logique d'ajout de fichier de manière à ce que cela marche pour n'importe quel fichier autre que celui sur la qualité des vins.